Algorithmen und Datenstrukturen

Einführung

Prof. Justus Piater, Ph.D.

9. März 2022

Dieser Kurs folgt in weiten Teilen dem sehr empfehlenswerten Lehrbuch Data Structures and Algorithms in Java [Goodrich u. a. 2014].

Inhaltsverzeichnis

1	Organisatorisches	1
2	Abstraktionsebenen der Programmierung	3
3	Abstrakte Datentypen, Datenstrukturen und Algorithmen	5
1	Organisatorisches	

Ziele dieser Lehrveranstaltung [Slide 1]

Grundbegriffe:

- Abstrakter Datentyp (ADT): Welche Operationen sollen auf den Daten effizient ausgeführt werden?
- **Datenstruktur** (DS): Welche Repräsentation meiner Daten eignet sich hierfür?
- *Algorithmus*: *Wie* können die gefragten Operationen effizient auf dieser Datenstruktur durchgeführt werden?

Kenntnisse und Kompetenzen:

- Standard-ADT sowie Standard-DS + Algorithmen
- Analysemethoden (Korrektheit, Verhalten, Effizienz) von Algorithmen + DS
- Design und Analyse neuer ADT, DS + Algorithmen

Organisation dieser Lehrveranstaltung [Slide 2]

Alle Informationen und Materialien finden sich auf der Homepage der Lehrveranstaltung: https://iis.uibk.ac.at/courses/2022s/703010/

Vorlesung: Einführung neuen Materials

- Kerninhalte (siehe auch die Kurzvideos)
- Ergänzende Inhalte
- Fragen und Antworten

Hausarbeiten: Theoretische Übungen; Programmierübungen

- Ausgabe: zum PS am Tag nach der Vorlesung
- Abgabe: am Tag vor der nächsten Vorlesung
- Besprechung: im Proseminar 8 Tage nach der Vorlesung

Proseminar: Übungen zum Thema der Vorlesung von vor 8 Tagen

- Präsentationen der vergangenen Hausarbeit
- Besprechung der aktuellen Hausarbeit

Interaktion [Slide 3]

Während der Live-Veranstaltungen

- verbal
- ARSnova

Außerhalb der Live-Veranstaltungen

- OLAT-Forum
 - einziger Kommunikationskanal (damit alle profitieren)



31095224

Umfrage über ARSnova [Slide 4]

Diese Lehrveranstaltung...

A: ist Teil meines Bachelorstudiums Informatik

B: ist Teil eines anderen Curriculums (Lehramt, Erweiterungsstudium, ...)

C: besuche ich als Gast

D: weiß nicht

Bewertung [Slide 5]

Vorlesung:

Klausur

• am Termin der letzten Sitzung

Proseminar:

- Midterm 2022-05-04 zur Vorlesungszeit
- Präsentationen
- Aufgabenzettel

2 Abstraktionsebenen der Programmierung

Programmieren 1945 (ENIAC) [Slide 6]

Rechnerarchitektur: von Neumann (CPU, adressierbarer Speicher)

 ${\bf Programmierung:} \ {\bf Byte-Sequenzen} \ ({\it opcodes}), \ {\bf die} \ {\bf elementare} \ {\bf mathematische} \ {\bf und}$

logische Operationen repräsentieren (Maschinencode)

Interaktion: = Programmierung

Programmieren heute [Slide 7]

Rechnerarchitektur: in den Grundlagen unverändert

Programmierung:

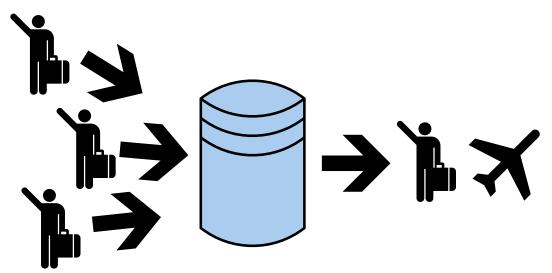
- Höhere Programmiersprachen
 - übersetzt in Maschinencode (C++, C, Rust, Go)
 - übersetzt in Bytecode für eine virtuelle Maschine (Java)
 - interpretiert = zur Laufzeit übersetzt in Bytecode für eine virtuelle Maschine oder ("jit") in Maschinencode (Julia, R, Python, Ruby, JavaScript, Lisp)
- Bibliotheken von *Datenstrukturen* und *Algorithmen*, sogar in Programmiersprachen integriert (hier Python):

```
dic['computer'] = 'Rechner'
```

• Domain-Specific Languages

Interaktion: Grafische Nutzeroberflächen, Touchscreens, gesprochene Sprache

Beispiel: Last-Minute-Fluggäste priorisieren [Slide 8]



Viele Abstraktionsebenen [Slide 9]

- 1. Last-Minute-Fluggäste nach Frequent-Flyer-Status einordnen.
- 2. Zwei voneinander unabhängige Schleifen:
 - Ankommenden Passagier einfügen
 - Passagier mit höchstem Status herausholen
- 3. Vorrangwarteschlange (abstrakter Datentyp)
- 4. Implementierung auf Basis eines *Heaps* (*Datenstruktur*)
- 5. Beschreibung der Funktionsweise der Operationen insert() und removeMin() (Algorithmen)
- 6. Implementation der Datenstruktur und Algorithmen in Java
- 7. Java Bytecode
- 8. ... Entsprechendes für die JVM ...
- 9. ... Entsprechendes für die CPU ...
- 10. ... Halbleiter ...
- 11. ... Quantenphysik ...

Breite Kompetenzen in der Informatik [Slide 10]

- Abstraktion und Formalisierung des Problems
- Design und Analyse möglicher Lösungen auf Basis abstrakter Datentypen
- Design und Analyse möglicher Implementationen auf Basis von Datenstrukturen und Algorithmen

Wichtig

Grundlage: Kenntnis von und kompetenter Umgang mit

- Standardlösungen (abstrakten Datentypen, Datenstrukturen, Algorithmen) und ihren Eigenschaften
- Analysemethoden für Algorithmen und Datenstrukturen

3 Abstrakte Datentypen, Datenstrukturen und Algorithmen

Die drei zentralen Grundbegriffe dieser Lehrveranstaltung sind der abstrakte Datentyp, die Datenstruktur, und der Algorithmus.

Beispiel: ADT Vorrangwarteschlange (Priority Queue) [Slide 11]

Definition:

- Datensatz = Schlüssel, Wert
- Totalordnung auf der Menge der Schlüssel Informell: Zwei Schlüssel sind entweder identisch, oder einer ist *kleiner* als der andere; diese Relationen zwischen beliebigen Schlüsseln enthalten keine Widersprüche.
- Zwei Operationen:

```
insert(k, v) // fügt Wert v unter Schlüssel k ein
removeMin() // entfernt v mit min. k und liefert v zurück
```

Implementierung mit verschiedenen *DS* möglich:

- unsortiertes Array
- sortierte verkettete Liste
- Heap (Haufen; partiell sortierter Baum)

Effizienz der *Algorithmen*, die die zwei Operationen implementieren?

Um diese Begriffe zu verdeutlichen, betrachten wir das Beispiel der Vorrangwarteschlange, wie sie z.B. dafür verwendet werden kann, Last-Minute-Passagiere entsprechend ihrer Priorität zu berücksichtigen, unabhängig von oder nicht nur gemäß der Reihenfolge ihres Auftauchens.

Eine Vorrangwarteschlange behandelt Datensätze in der Form von Schlüssel-Wert-Paaren. Hier betrachten wir den Schlüssel vereinfacht als einen Zahlenwert, der bspw. die Priorität eines Passagiers repräsentiert. Der zugehörige Wert ist der Datensatz des Passagiers in der Datenbank der Fluggesellschaft.

Der abstrakte Datentyp der Vorrangwarteschlange ist durch zwei Operationen definiert: insert(k, v) fügt den Wert v unter dem Schlüssel k in die Vorrangwarteschlange ein, und removeMin entfernt das Schlüssel-Wert-Paar mit dem niedrigsten Schlüsselwert k, also der höchsten Priorität, aus der Vorrangwarteschlange, und liefert den zugehörigen Wert v zurück.

Welche Datenstrukturen eigenen sich für eine Vorrangwarteschlange? Mit anderen Worten, welche Datenstrukturen erlauben effiziente Algorithmen für die beiden Methoden insert() und removeMin()? Verschiedene Datenstrukturen haben verschiedene Vorund Nachteile.

Wir können z.B. eine Vorrangwarteschlange auf der Basis eines unsortierten Arrays implementieren. Damit ist insert() einfach und effizient implementierbar: Wir fügen das Schlüssel-Wert-Paar einfach hinter den letzten Eintrag des Arrays ein, was sich in konstanter Laufzeit machen lässt, unabhängig von der Anzahl n der Einträge in der Vorrangwarteschlange. Der Preis dafür ist, dass removeMin das gesamte Array nach dem Eintrag mit dem kleinsten Schlüssel durchsuchen muss, was eine Laufzeit proportional zu n beansprucht.

Wenn wir dagegen eine sortierte Liste verwenden, dann kann removeMin das höchstpriorisierte Element einfach am Kopf der Liste abgreifen, in konstanter Zeit. Nun allerdings muss insert () die Liste im Schnitt zur Hälfte durchlaufen, um seinen Eintrag an der richtigen Stelle einzusortieren. Dies beansprucht wiederum eine Zeit proportional zu n.

Wäre es nicht schön, eine Datenstruktur zu haben, die einen Kompromiss zwischen diesen beiden Laufzeiten ermöglicht, und damit eine kürzere Gesamtlaufzeit über viele Operationen hinweg? Eine solche Datenstruktur ist der sogenannte heap, der es erlaubt, sowohl insert() als auch removeMin() mit einer Laufzeit logarithmisch in n zu implementieren.

Abstrakte Datentypen (ADT) [Slide 12]

Grundbegriffe:

- ADT: Welche Operationen sollen auf den Daten effizient ausgeführt werden? Definiert eine Schnittstelle (interface) in der Form von Methoden, die auf der Basis anderer ADT und/oder DS implementiert werden können
- DS: Welche Repräsentation meiner Daten eignet sich hierfür?

 Definiert mittels Grafentheorie (Bäume), Mathematik (Vektor), ...
- *Algorithmus*: *Wie* können die gefragten Operationen effizient auf dieser Datenstruktur Schritt für Schritt durchgeführt werden?

Definiert z.B. durch Pseudocode

Wichtig

Algorithmen greifen auf Datenstrukturen zu; sie gehören untrennbar zusammen.

Nach diesem Beispiel stellen wir noch einmal die drei Grundbegriffe heraus:

Ein abstrakter Datentyp beschreibt, welche Operationen auf den Daten ausgeführt werden sollen. Gegebenenfalls ist wichtig, welche dieser Operationen besonders effizient sein sollen. Ein abstrakter Datentyp sagt jedoch nichts darüber aus, wie diese Operationen ausgeführt werden, sondern nur, welche.

Damit beschreibt ein abstrakter Datentyp eine Schnittstelle zu den Daten, auf englisch interface. Diese Schnittstelle definiert Methoden, die dann später ggf. durch andere abstrakte Datentypen oder Datenstrukturen implementiert werden können.

In unserem Beispiel der Vorrangwarteschlange bestand die Schnittstelle in den Methoden insert() und removeMin(). Nur über diese Schnittstelle, also nur über diese beiden Methoden, kann auf die Daten in der Vorrangwarteschlange zugegriffen werden.

Eine Datenstruktur beschreibt, wie die Daten so repräsentiert werden können, dass für die gewünschten Methoden effiziente Algorithmen existieren. Datenstrukturen werden durch geeignete formale Systeme beschrieben, die aus der Grafentheorie stammen, wie z.B. Bäume oder gerichtete Grafen, oder aus der Mathematik, wie z.B. Vektoren oder Matrizen.

Ein Algorithmus ist eine Schritt-für-Schritt-Beschreibung der Art und Weise, wie die Methoden tatsächlich auf den Datenstrukturen ausgeführt werden. Es ist hiermit klar, dass Datenstrukturen und Algorithmen untrennbar zusammengehören.

Zur Beschreibung von Algorithmen verwenden wir manchmal konkrete Programmiersprachen, aber häufiger sogenannten Pseudocode.

Pseudocode [Slide 13]

- Menschenlesbar, nicht unbedingt maschinenlesbar
- Keine formale Syntax oder Semantik
- Reduziert auf ein Minimum; ohne Spezifika realer Programmiersprachen
- Ausreichend Detail für die Spezifikation der Funktionsweise und für die Analyse von Korrektheit und Effizienz

Beispiel

return m

```
Algorithm arrayMax(A,n):

Require: An array A storing n \ge 1 integers.

Ensure: Return the maximum element in A.

m \leftarrow A[0]

for i \leftarrow 1 to n-1 do

if m < A[i] then

m \leftarrow A[i]
```

Pseudocode dient der kompakten Beschreibung von Algorithmen ohne den Ballast realer Programmiersprachen. Wir verwenden ihn hier ohne formale Definition, sondern verlassen uns darauf, dass seine Notation für angehende Informatik-Fachleute intuitiv verständlich ist. Nichtsdestotrotz ist Pseudocode hinreichend detailliert, um Algorithmen und ihre einzelnen Berechnungsschritte exakt zu beschreiben und ihre Analyse hinsichtlich Korrektheit und Effizienz zu ermöglichen.

Das Beispiel beschreibt einen Algorithmus namens $\mathtt{arrayMax}()$. Er verlangt, dass ein Array mit mindestens einem Element übergeben wird; die Anzahl der Elemente des Arrays steht im Parameter n. Dann verspricht er, dass er das größte Element des Arrays zurückliefern wird. Impliziert ist das Versprechen, dass der Algorithmus in endlicher Zeit terminieren wird.

Nach dieser Spezifikation folgen die einzelnen Berechnungsschritte. Der linksweisende Pfeil bedeutet, dass der Wert auf der rechten Seite der Variablen auf der linken Seite zugewiesen wird. Die fett gedruckten Schlüsselwörter und die Array-Indizierung mit eckigen Klammern sind realen Programmiersprachen nachempfunden, ohne einer bestimmten Programmiersprache entsprechen zu wollen. Der Rest sind übliche mathematische Operatoren.

Mit solchem Pseudocode werden wir im Laufe dieser Lehrveranstaltung viele unserer Algorithmen beschreiben.

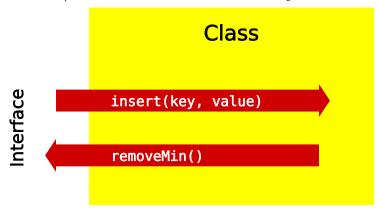
Quiz [Slide 14]

Genau eine der folgenden Aussagen ist nicht richtig. Welche?

- A: Ein abstrakter Datentyp definiert, welche Operationen auf Daten ausgeführt werden sollen.
- B: Eine Datenstruktur beschreibt, welche Algorithmen auf einem abstrakten Datentyp ausgeführt werden.
- C: Ein Algorithmus ist eine Schritt-für-Schritt-Beschreibung einer Methode, um eine bestimmte Berechnung durchzuführen.
- D: weiß nicht

ADT und Objekt-orientierte Programmierung (OOP) [Slide 15]

AlgorithmikOOPADTInterfaceDS + AlgorithmenKlasseInstanzen/DatenObjekte



ADT in Java (vereinfacht) [Slide 16]

```
public interface PriorityQueue {
   public void insert(int key, Object value);
   public Object removeMin();
}

public class SortedListPriorityQueue
   implements PriorityQueue {
   public void insert(int key, Object value) { ... }
   public Object removeMin() { ... }
}

public class HeapPriorityQueue
   implements PriorityQueue {
   public void insert(int key, Object value) { ... }
   public Object removeMin() { ... }
}

PriorityQueue pqOne = new SortedListPriorityQueue();
PriorityQueue pqTwo = new HeapPriorityQueue();
```

Beispiel: ADT Zuordnungstabelle (Map, Dictionary) [Slide 17]

Definition:

- Datensatz = Schlüssel, Wert
- (keine Ordnung auf der Menge der Schlüssel notwendig)
- Drei Operationen:

```
get(k) // liefert Wert v von Schlüssel k zurück (oder null)
put(k, v) // fügt Wert v unter Schlüssel k ein
remove(k) // entfernt v mit k und liefert v zurück (oder null)
```

Beispiel

In Python:

```
dic = {} # instantiate a Dictionary
dic["computer"] = "Rechner" # put("computer", "Rechner")
print(dic["computer"]) # get("computer")
del dic["computer"] # remove("computer")
```

DATENSTRUKTUREN (... und Algorithmen) [Slide 18]

Wichtig

Denken in

- 1. abstrakten Datentypen
- 2. Datenstrukturen
- 3. Algorithmen

in dieser Reihenfolge!

...git actually has a simple design, with stable and reasonably well-documented data structures. In fact, I'm a huge proponent of **designing your code around the data**, rather than the other way around, and I think it's one of the reasons git has been fairly successful [...] I will, in fact, claim that the difference between a bad programmer and a good one is whether he considers his code or his data structures more important. Bad programmers worry about the code. Good programmers worry about **data structures and their relationships**.

[Linus Torvalds 2006-07-27 in einer E-Mail an die Git-Mailingliste; Hervorhebungen J.P.]